

RAPPORT — Data Refinement (Cafe Sales Dirty Data)

Contexte

Objectif : nettoyer et transformer un dataset CSV “sale” pour obtenir une donnée cohérente et exploitable, notamment pour des **analyses temporelles par mois**.

Dataset : *Cafe Sales (Dirty Data)* — **10 000 lignes, 8 colonnes**.

Problèmes

- Colonnes numériques (*Quantity*, *Price Per Unit*, *Total Spent*) lues en **texte**.
- Valeurs manquantes (fortes sur *Location* et *Payment Method*).
- Valeurs invalides : *UNKNOWN*, *ERROR* (ex: *Total Spent*="ERROR", *Transaction Date*="UNKNOWN").
- 0 doublon strict.

Solutions

- Remplacement de *UNKNOWN/ERROR/vides* par *NaN* pour traiter correctement les manquants.
- Conversion des types : numériques nombre, date *datetime*.
- Recalcul de *Total Spent* = *Quantity* × *Price Per Unit* (valeur dérivée cohérence).
- Suppression des lignes sans *Item* (transaction non exploitable).
- Suppression des lignes sans *Transaction Date* (analyse mensuelle impossible sinon).
- Remplacement des manquants de *Payment Method* et *Location* par le **mode** (évite de perdre trop de lignes).

Résultat

- Dataset nettoyé : *DATA/PROCESSED/clean_cafe_sales.csv*
- Taille finale : **8147 lignes**
- Pas de date vide, pas de *UNKNOWN*, variables numériques cohérentes.
- Dataset final enrichi : *DATA/PROCESSED/final_cafe_sales.csv* avec colonnes temporelles (*Year*, *Month*, etc.) + base pour calculer le chiffre d'affaires par mois.